

BÁO CÁO XÂY DỰNG NGŨ LIỆU ĐƠN NGỮ CHỮ HÁN CỔ VỀ LỊCH SỬ TRUNG QUỐC

Học phần: [Điền tên học phần]

Nhóm sinh viên: [Điền họ tên và MSSV]

Tháng 7 năm 2026

Tóm tắt. Báo cáo trình bày quy trình xây dựng ngữ liệu đơn ngữ chữ Hán cổ/văn ngôn thuộc lĩnh vực lịch sử Trung Quốc thời phong kiến. Từ tám tác phẩm đầu vào, hệ thống chuẩn hóa cấu trúc, làm sạch, tách câu và sinh tiền gán nhãn thực thể có tên (NER). Kết quả hiện tại gồm 57474 bản ghi, 271471 câu và 192109 thực thể tiền gán nhãn, được xuất thành 787 thư mục quyển. Đây là bản *draft*: các offset và cấu trúc đã vượt qua kiểm tra tự động, nhưng nhãn thực thể chưa được xem là gold cho đến khi hoàn tất hiệu đính thủ công.

1. Giới thiệu

1.1. Mục tiêu của đồ án

Mục tiêu là tạo một corpus có cấu trúc phục vụ nghiên cứu xử lý ngôn ngữ tự nhiên trên văn bản Hán cổ, tập trung vào sử liệu Trung Quốc thời phong kiến. “Đơn ngữ” được hiểu là trường văn bản nghiên cứu chỉ chứa tiếng Hán, không ghép song song với bản dịch tiếng Việt. Thông tin tiếng Việt, nếu có, chỉ đóng vai trò metadata nhận diện tác phẩm và không được đưa vào nội dung câu.

1.2. Bài toán được giao

Đầu vào là các tệp văn bản thô, trong đó tiêu đề tác phẩm, tiêu đề quyển, dòng trống và nội dung chính còn trộn lẫn. Đồ án cần biến nguồn này thành dữ liệu JSONL theo từng quyển, tách câu và gán các nhãn thực thể theo schema nộp bài: PER, LOC, ORG, TITLE, TME và NUM. Trong nội bộ, hệ thống giữ nhãn chi tiết hơn như BOOK, OFFICIAL_TITLE, DYNASTY và POLITY, sau đó ánh xạ sang schema đầu ra.

1.3. Phạm vi dữ liệu và kết quả mong đợi

Phạm vi gồm tám tác phẩm có trong thư mục dataset/, không tự động tải thêm nguồn bên ngoài và không thực hiện OCR. Sản phẩm mong đợi gồm corpus đã làm sạch, corpus tiền gán nhãn, tập pilot phục vụ hiệu đính, bản xuất theo từng quyển, manifest SHA-256 và báo cáo kiểm tra tuân thủ. Bản nộp cuối chỉ được tạo khi mapping nhãn đã được xác nhận và toàn bộ dữ liệu trong phạm vi nộp đã được con người duyệt.

2. Dữ liệu và công cụ sử dụng

2.1. Mô tả và nguồn dữ liệu đầu vào

Nguồn thô gồm tám tệp UTF-8 do đề bài cung cấp. Mỗi tệp tương ứng một tác phẩm; các dòng dạng 卷一, 卷上, 卷015b được dùng để xác định ranh giới quyển. Danh sách nguồn được thể hiện trong Bảng 1.

Quy tắc làm sạch bảo toàn nguyên văn: không dịch, không chuyển giản thể/phồn thể và không tự sửa chữ nghi là lỗi OCR. Hệ thống chỉ loại tiêu đề công việc, heading quyển, dòng trống và boilerplate đã nhận diện; mọi quyết định loại bỏ được lưu trong build/audit_decisions.jsonl. Những đoạn chứa URL hoặc placeholder OCR được giữ lại nhưng đánh dấu needs_review.

Bảng 1: Các tác phẩm trong dữ liệu đầu vào.

Tác phẩm	Giai đoạn	Thể loại/đặc trưng
北史	Nam-Bắc triều	Chính sử
北齊書	Bắc Tề	Chính sử
諸蕃志	Tống	Địa lý, ngoại quốc
舊唐書	Đường	Chính sử
舊五代史	Ngũ Đại	Chính sử
東觀漢記 (四庫全書本)	Đông Hán	Sử thư
漢書	Tây Hán	Chính sử
後漢書	Đông Hán	Chính sử


2.2. Công cụ, thư viện và mô hình

Pipeline được viết bằng Python 3.11 trở lên, quản lý môi trường bằng uv và cấu hình bằng TOML. Các thành phần chính gồm bộ tách câu dựa trên quy tắc, biểu thức chính quy, từ điển dạng trie, seed gazetteer và bộ hợp nhất ứng viên có thứ tự ưu tiên xác định. Dữ liệu duyệt được trao đổi theo định dạng tương thích Doccano 1.8.x. Kiểm thử dùng pytest; kiểm tra mã nguồn dùng Ruff.

Các adapter cho CBDB và CHGIS đã được chuẩn bị để tạo seed cache có manifest, nhưng không tự tải dữ liệu và không tham gia nếu người chạy chưa cung cấp nguồn. Các dependency cho mô hình phân đoạn/NER cũng được khai báo ở dạng tùy chọn. Do đó, số liệu trong báo cáo này chỉ đến từ hai nguồn ứng viên regex và seed, không phải dự đoán của mô hình học máy.

3. Quy trình thực hiện

3.1. Tổng quan



Quy trình tách rõ dữ liệu nguồn, tiền gán nhãn và gold. Cách tổ chức này tránh việc xem kết quả heuristic là nhãn đúng, đồng thời cho phép truy vết từ thực thể đầu ra về tệp và dòng nguồn.

3.2. Các bước chính

- Chuẩn hóa và tách quyển.** Parser nhận diện nhiều biến thể heading, chuẩn hóa khóa (volume_number, volume_part) và kiểm tra đường dẫn đầu ra không va chạm.
- Làm sạch có kiểm toán.** Những dòng bị loại được ghi cùng lý do; 49 bản ghi có dấu hiệu URL/placeholder OCR được giữ lại để con người quyết định.
- Tách câu.** Văn bản được chia theo 。 ! ? , đồng thời bảo vệ dấu câu nằm trong ngoặc. Mỗi câu có sentence_id, offset bắt đầu/kết thúc và trạng thái duyệt.
- Tiền gán nhãn.** Regex và seed gazetteer sinh ứng viên. Bộ merger xử lý cùng span, lồng nhau, giao cắt và tie-break một cách xác định. Mỗi thực thể giữ sources, priority_score và danh sách nhãn đã hợp nhất.
- Lấy mẫu và hiệu đính.** Tập pilot ngẫu nhiên gồm 200 câu, phân tầng đều theo tám tác phẩm (25 câu/tác phẩm, seed 42); 15% được dành cho gán nhãn kép. Một tập diagnostic riêng tập trung vào các trường hợp khó.
- Xuất dữ liệu.** Chế độ draft cho phép khảo sát tiền gán nhãn. Chế độ final bắt buộc strict validation, mapping được xác nhận, câu/thực thể đã duyệt và conflict đã giải quyết. Việc ghi output dùng staging và đổi tên trong cùng filesystem để tránh

submission dở dang.

4. Kết quả đạt được

4.1. Khối lượng dữ liệu xử lý

Bảng 2: Thống kê của lần chạy hiện tại.

Chỉ tiêu	Số lượng	Chỉ tiêu	Số lượng
Tập/tác phẩm nguồn	8	Ký tự nội dung	7 359 348
Bản ghi	57 474	Câu	271 471
Quyển đầu ra	787	Thực thể tiền gán nhãn	192 109
Dòng audit	3 817	Bản ghi cần xem lại làm sạch	49
Conflict chưa giải quyết	1 362	Bản ghi chứa conflict	1 224

Phân bố nhãn nội bộ được trình bày ở Bảng 3. Hai nhãn PERSON và NUMBER chưa có ứng viên trong lần chạy hiện tại; đây là thiếu hụt coverage, không phải bằng chứng rằng corpus không có người hay số lượng.

Bảng 3: Phân bố 192 109 thực thể tiền gán nhãn.

Nhãn	Số lượng	Nhãn	Số lượng
LOCATION	83 061	OFFICIAL_TITLE	63 463
TIME	26 035	BOOK	14 267
DYNASTY	3 034	POLITY	2 249

4.2. Các sản phẩm đầu ra

Artifact	Nội dung
build/corpus.jsonl	Corpus đã chuẩn hóa và tách quyển/câu
build/corpus_preannotated.jsonl	Corpus có thực thể heuristic và provenance
build/audit_decisions.jsonl	Nhật ký quyết định làm sạch
build/pilot/	Mẫu random và diagnostic để hiệu đính
build/submission/	787 thư mục quyển, manifest và validation report
build/annotation_samples.html	Trang HTML minh họa trực quan các nhãn

Manifest của bản draft ghi 271 471 câu, 192 109 thực thể, mapping phiên bản 0.2.0 và checksum SHA-256 của corpus nguồn. Mỗi thực thể trong file nộp chỉ còn bốn trường tối thiểu: text, label, start, end; provenance chỉ tồn tại trong artifact nội bộ.

4.3. Ví dụ minh họa

Ví dụ thực từ 北史:

二年 春正月癸卯，拜沮渠無諱為征西大將軍、涼州牧、酒泉王。

Trong đó 二年 được gán TIME, 大將軍 là OFFICIAL_TITLE, và 涼州 là LOCATION. Ví dụ cũng cho thấy hạn chế quan trọng: tên người 沮渠無諱 chưa được nhận diện và địa danh 酒泉 có thể bị bỏ sót. Một ví dụ khác từ 諸蕃志 nhận diện 寶慶元年 là TIME và 大夫 là OFFICIAL_TITLE. Vì đây là preannotation, các đoạn tô màu là để xuất cho người gán nhãn, không phải đáp án gold.

5. Đánh giá và thảo luận

5.1. Cách đánh giá

Đánh giá được chia thành hai tầng. Tầng cấu trúc kiểm tra offset, chuỗi text[start:end], nhãn hợp lệ, phạm vi câu, đường dẫn quyển, shape đầu ra và chuỗi checksum. Tầng chất lượng NER dự kiến dùng tập gold pilot để tính precision, recall và F1 strict theo entity, F1 biên, kết quả theo từng nhãn, confusion matrix và độ chính xác nhãn trên các biên đã khớp.

5.2. Kết quả đánh giá hiện tại

Kiểm tra	Kết quả	Diễn giải
Offset-only validation	Đạt	Offset và cấu trúc cơ bản hợp lệ
Draft compliance	0 fatal, 0 warning	Shape, thư mục và manifest hợp lệ
Kiểm thử phần mềm	190 test đạt	Bảo vệ hành vi parser, merger, I/O và export
Ruff lint/format	Đạt	Mã nguồn vượt qua quality gate tĩnh
Strict validation preannotation	464 853 fatal	Kỳ vọng vì chưa human-review
Entity-level F1	Chưa có	Chưa có gold pilot đã hiệu đính

Số lỗi strict gồm 271 471 câu chưa duyệt, 192 109 thực thể chưa duyệt, 1 224 bản ghi còn conflict và 49 bản ghi cần quyết định làm sạch. Các số này không nên được diễn giải là 464 853 dự đoán sai; chúng là các cổng quy trình ngăn bản preannotation bị xuất nhầm thành final. Tương tự, 190 kiểm thử phần mềm chứng minh tính ổn định của implementation, không thay thế cho precision, recall hoặc F1 của dữ liệu.

5.3. Vấn đề gặp phải và phân tích nguyên nhân

- **Biến thể heading quyển.** Cùng một nguồn có nhiều cách ghi số và phần quyển. Parser ban đầu có thể gặp nhầm; nguyên nhân là xem chuỗi heading như tên tự do thay vì khóa chuẩn hóa.
- **Nhập nhằng thực thể.** Một span có thể là triều đại, chính thể, địa danh hoặc nằm trong chức danh dài. Regex chỉ quan sát bề mặt nên sinh cả false positive, false negative và conflict.
- **Coverage không cân bằng.** Gazetteer địa danh/chức quan phong phú hơn tên người và số lượng; đồng thời tên người Hán cổ thường không có dấu hiệu hình thức cố định. Đây là lý do LOCATION và OFFICIAL_TITLE chiếm ưu thế, còn PERSON/NUMBER chưa được sinh trong lần chạy này.
- **Nhiều nguồn.** Placeholder OCR và URL nằm giữa dòng không thể loại bằng quy tắc boilerplate mà không có nguy cơ xóa văn bản thật. Hệ thống vì vậy giữ nguyên và chuyển sang hàng đợi duyệt.
- **Thiếu gold.** Không thể báo cáo F1 đáng tin cậy bằng cách so heuristic với chính nó. Cần gán nhãn độc lập, giải quyết bất đồng và khóa phiên bản guideline trước khi đánh giá.

6. Kết luận và hướng phát triển

Đồ án đã hoàn thành đường ống có thể tái lập từ tám tập nguồn đến corpus JSONL, bao gồm tách 787 quyển, làm sạch có audit, tách 271 471 câu, sinh 192 109 thực thể tiền gán nhãn, lấy mẫu pilot, trao đổi Doccano, export nguyên tử và kiểm tra checksum. Source code vượt qua test và lint; bản draft vượt qua compliance.

Hạn chế lớn nhất là chưa có gold corpus đã được người làm chuyên môn duyệt,

mapping cuối chưa được xác nhận và coverage của PERSON/NUMBER còn thiếu. Vì vậy, hướng phát triển ưu tiên là: (1) hiệu đính 200 câu pilot và đo agreement giữa annotator; (2) phân tích lỗi theo nhãn để mở rộng gazetteer; (3) tích hợp CBDB/CHGIS có kiểm soát; (4) thử mô hình pretrained cho Hán cổ và so sánh với baseline regex-seed; (5) active learning để ưu tiên câu có conflict hoặc độ bất định cao. Chỉ sau các bước này mới xác nhận mapping, chạy strict validation và đóng gói bản final.

Tài liệu

- [1] L. Li và cộng sự, “EvaHan 2024: Overview of the First International Ancient Chinese Translation Bakeoff,” ACL Anthology, 2024. <https://aclanthology.org/2024.lt4hala-1.15/>
- [2] L. Li và cộng sự, “EvaHan 2025: Overview of Named Entity Recognition and Sentence Segmentation Evaluation for Ancient Chinese,” ACL Anthology, 2025. <https://aclanthology.org/2025.alp-1.17/>
- [3] Y. Xu và cộng sự, “GuNER 2023: Ancient Chinese Named Entity Recognition Evaluation,” ACL Anthology, 2023. <https://aclanthology.org/2023.lt4hala-1.18/>
- [4] Tài liệu nguồn của đồ án, dataset/README.md và các hướng dẫn trong docs/, phiên bản truy cập tháng 7 năm 2026.