

Báo cáo nghiên cứu web cho HCH corpus lịch sử chữ Hán

Ngày kiểm tra web: 13-07-2026. Báo cáo này tách riêng phần **được nguồn xác nhận** với phần **khuyến nghị suy luận cho đề án**. Kết luận ngắn gọn là: với corpus hiện tại đã ở dạng văn bản và thiên về văn ngôn/phồn thể, hướng thực tế nhất là dùng **pipeline lai**. Ở bước tách câu, lấy **dấu câu hiện có làm tín hiệu chính**, thêm lớp **bảo vệ chú thích/ngoặc/chú giải**, rồi chỉ dùng mô hình chuyên biệt cho các đoạn **thiếu dấu câu hoặc dấu câu không đáng tin**. Ở bước NER, không nên kỳ vọng HanLP, CKIP, spaCy hay Stanza “giải quyết ngay” văn bản sử học Hán cổ, vì tài liệu chính thức của chúng chủ yếu công bố mô hình trên dữ liệu tiếng Trung hiện đại như MSRA, OntoNotes hoặc web/news text; thay vào đó, nên dùng chúng làm baseline hoặc công cụ kỹ thuật, còn mô hình chính nên là **Transformers fine-tune trên backbone cổ văn** như SikUBERT, GuwenBERT hoặc GujiRoBERTa với một schema nhãn nhỏ gọn, có pilot annotation và adjudication rõ ràng. ¹

Khuyến nghị thực thi cụ thể cho đề tài sinh viên là: **tách câu theo hai tầng**, trong đó tầng một là rule-based trên punctuation và markup có kiểm soát; tầng hai là mô hình cổ văn chỉ chạy trên các trường hợp “khó”. Với NER, nên **lưu gold ở dạng span offsets chuẩn hóa**, nhưng khi huấn luyện thì **chiều sang BIOES/BMES ở mức ký tự** vì đây là cách được các benchmark cổ văn gần đây dùng rộng rãi; EvaHan2025 dùng BMES và đánh giá ở **mức thực thể hoàn chỉnh**, không phải mức ký tự, còn Stanza cũng yêu cầu BIOES khi huấn luyện model NER riêng. Với ràng buộc bảo tồn raw corpus, mọi lớp xử lý nên là **đẫn xuất**, không ghi đè văn bản gốc. ²

Tách câu văn ngôn

Văn ngôn khác tiếng Trung hiện đại ở chỗ nhiều nguồn **vốn không có ranh giới câu và không có dấu câu hiện đại**, nên việc câu đoạn phụ thuộc mạnh vào kiến thức ngữ nghĩa và cú pháp. EvaHan2024 mô tả đây là một tác vụ nền tảng nhưng còn khó, và nhấn mạnh rằng trên dữ liệu unpublished/unseen, kết quả còn thấp hơn rõ rệt so với dữ liệu quen thuộc; đồng thời các mô hình LLM tuy mạnh hơn baseline truyền thống nhưng có thể **làm đổi 1–2% ký tự gốc** do over-generation, nên phải có bước hậu xử lý để giữ nguyên văn bản. Các nghiên cứu gần đây cũng xem **punctuation và segmentation là bài toán liên đới**, vì trong cổ văn, dấu câu hiện đại đồng thời chính là tín hiệu chia câu. ³

Điểm quan trọng cho corpus HCH là: vì corpus hiện tại **đã là text**, lại có ví dụ chứa dấu , hướng tốt nhất **không phải** giả định rằng mọi câu đều vô dấu câu như bản khắc cổ. Thay vào đó, nên xem dấu câu hiện có là “tín hiệu biên tập” có giá trị, nhưng không mặc nhiên tuyệt đối. Điều này phù hợp với thực tế của các công cụ hiện hành: HanLP có `NgramSentenceBoundaryDetector`, nhưng chính tài liệu của HanLP nói rõ bộ phát hiện này **chỉ hoạt động khi văn bản có các dấu câu EOS mà config định nghĩa**, còn pipeline của HanLP nhìn chung cũng khuyến nghị đầu vào ở mức **sentence-level**. Vì vậy, HanLP không nên là lựa chọn chính cho đoạn thiếu dấu câu hoàn toàn. ⁴

Bảng so sánh lựa chọn tách câu

Lựa chọn	Cổ văn / phần thể	Chạy offline Python	Giấy phép	Điểm mạnh	Hạn chế	Độ hợp HC
Rule-based dựa trên punctuation hiện có	Phù hợp nếu corpus đã có 。 ! ? ; : và dấu ngoặc/chú thích	Có	Tự viết	Dễ kiểm soát, giữ nguyên raw, tái lập tốt, rất hợp với corpus đã làm sạch	Yếu khi thiếu dấu câu hoặc dấu câu nhiều; rule dễ phình to	Ph nh làn ba sản
HanLP NgramSentenceBoundaryDetector	Không chuyên biệt cổ văn; detector dựa trên punctuation	Có	Code Apache 2.0; tài liệu HanLP nêu models/ REST APIs dưới CC BY-NC-SA 4.0	Có component tách ranh giới câu sẵn; dễ tích hợp Python	HanLP nói rõ detector không hoạt động tốt nếu không có punctuation xác định; NER/model công bố không phải ancient Chinese	Hợp ba kỹ thu kh nên lỗi
KoichiYasuoka roberta-classical-chinese-*-sentence-segmentation	Có, model card ghi rõ cho Classical Chinese; hỗ trợ dùng trực tiếp qua Transformers	Có	Apache-2.0	Chuyên cho classical Chinese; có sẵn base và large; inference trực tiếp bằng transformers	Model card không công bố benchmark mới trên corpus sử học Trung Quốc hiện đại của bạn; cần tự đánh giá	Lự ch sẵn hợp nh tro nh m độ

Lựa chọn	Cổ văn / phần thể	Chạy offline Python	Giấy phép	Điểm mạnh	Hạn chế	Độ hợp HC
Fine-tune GuwenBERT hoặc SikuBERT cho boundary tagging	Có; GuwenBERT pretrain trên cổ văn, SikuBERT/ SikuRoBERTa pretrain trên 四庫全書 bằng phần thể	Có	Apache-2.0	Chủ động thích nghi domain lịch sử; có thể huấn luyện boundary model riêng	Tốn gán nhân; GuwenBERT dùng dữ liệu đã quy giản sang giản thể nên lệch script với corpus phần thể	Kh ng mạ ch nâ cấp bas 7
XunziALLM / LLM fine-tune cho punctuation + segmentation	Có, README và paper EvaHan2024 mô tả rõ cho cổ văn	Có thể chạy local nếu có tài nguyên phù hợp	Apache-2.0	Kết quả mạnh trong EvaHan2024; thích hợp đoạn khó, thiếu punctuation	Có nguy cơ đổi ký tự gốc, paper chính họ phải thêm post- processing để sửa	Ch dù nh tân ch đo kh kh nên dù mặ địn toà cor 8

Khuyến nghị triển khai tách câu cho HCH là một **chiến lược ba bước**. Bước một, bảo vệ trước các span biên tập như ngoặc, trích dẫn, chú thích kiểu 〈案 ...〉, số quyển, mục lục, và các cặp dấu chưa muốn tách; đây là **đề xuất phương pháp** cho dự án, vì tôi không thấy một guideline chuẩn công bố riêng cho đúng pattern 〈案...〉 trong các nguồn đã tra. Bước hai, tách rule-based: mặc định cắt sau 。 ! ? ; với ; thì giữ như **major clause boundary** và chỉ nâng lên sentence boundary nếu đoạn hai vế đủ dài hoặc annotation guide của nhóm xác nhận; với : thì mặc định **không cắt ngay** mà coi là dấu dẫn nhập, trừ khi theo sau là lời dẫn/diển mục rõ ràng. Bước ba, đánh cờ các đoạn bất thường như quá dài, không dấu câu, hoặc có nhiều chú thích chen giữa để chạy model classical-Chinese và đưa vào hàng đợi review thủ công. Cách này bám sát kết quả nghiên cứu rằng rule-based thuần túy khó chống mơ hồ cú pháp, còn LLM/mô hình sâu mạnh hơn nhưng cần hậu kiểm để không làm lệch nguyên bản. ⁹

Về lựa chọn “phù hợp nhất” ở thời điểm hiện tại, nếu câu hỏi là **cho toàn bộ pipeline thật sự dùng được trong đồ án**, tôi không khuyến nghị một model đơn lẻ. Tôi khuyến nghị: **baseline sản xuất = rule-based punctuation splitter; model fallback = KoichiYasuoka sentence segmentation model hoặc model tự fine-tune trên SikuBERT/SikuRoBERTa; LLM/XunziALLM chỉ dùng trên ca khó**. Lý do là Koichi có model card rõ ràng cho Classical Chinese và chạy offline; SikuBERT/SikuRoBERTa lại có lợi thế script alignment với

phần thể; còn XunziALLM có thành tích tốt nhưng chính benchmark chỉ ra nguy cơ thay đổi ký tự. Đây là suy luận kỹ thuật dựa trên tài liệu hiện có, không phải khẳng định rằng một model duy nhất sẽ thắng tuyệt đối trên corpus HCH nếu chưa có tập gold riêng. ¹⁰

NER cho văn bản lịch sử Trung Quốc

Các nguồn gần đây cho thấy NER cổ văn đang chuyển từ bài toán “demo trên một corpus hẹp” sang benchmark tương đối nghiêm túc. EvaHan2025 là benchmark quốc tế đầu tiên cho NER Hán cổ, gộp dữ liệu **lịch sử** và **y học**, có tổng cộng **12 loại thực thể**, trong đó hai tập lịch sử dùng các nhãn như **person**, **geographical location**, **book title**, **official title**, **country name**, **time**. Paper cũng nhấn mạnh một vấn đề rất quan trọng cho đề tài của bạn: **các corpus hiện có dùng các schema rất khác nhau**, chưa có hệ phân cấp thực thể thống nhất cho ancient Chinese NER, vì vậy thiết kế schema cho HCH phải vừa đủ gọn để gán nhãn được, vừa đủ rõ để tránh “hầm bà lằng nhằng”. ¹¹

Một nguồn rất sát domain hơn là **GuNER2023**. Đây là bài đánh giá NER cổ tịch trên dữ liệu từ **二十四史**, quy mô **hơn 150.000 chữ**, với ba loại thực thể **人名, 书名, 官职名**, và hơn mười nghìn thực thể; best F1 báo cáo là **96,15%** trên closed track. Điểm đáng chú ý là GuNER2023 cho thấy NER sử học Hán cổ **hoàn toàn làm được** với hiệu năng cao khi schema gọn và domain hẹp. Tuy vậy, nó cũng cho thấy nếu schema quá hẹp thì sẽ không đáp ứng mục tiêu học thuật rộng hơn của HCH, nơi bạn đang muốn giữ cả địa danh, thời gian, triều đại, nhóm dân tộc, biến cố. ¹²

Ở chiều ngược lại, **WYWEB GLNER** là một benchmark hữu ích nhưng **không đủ** để làm schema đích, vì task GLNER trong WYWEB chỉ có hai loại: **bookname** và **other**, tức là quá coarse-grained cho sử liệu. Bản thân paper WYWEB cũng nói rõ đây là tập còn thô và cần nhãn hóa tinh hơn trong tương lai. Điều này làm WYWEB phù hợp hơn cho **khởi tạo model/so sánh backbone** hơn là dùng trực tiếp làm target label set cho HCH. ¹³

Về backbone và phương pháp, kết quả tốt gần đây trên EvaHan2025 đều đi theo hướng **PLM cổ văn + structured decoding**. Hệ của Lu & Lei dùng **GujiRoBERTa_jian_fan + BiLSTM + CRF** đạt **84,58 F1** ở closed track, cao hơn baseline **80,61**; hệ GRoWE dùng **GujiRoBERTa + word-word relation classification + ensemble** đạt **86,79 F1** trên public test, hơn baseline **6,18 điểm**. Ngoài ra, nghiên cứu của Ge trên **左傳** cho thấy gộp sentence segmentation và NER vào một tagging task thống nhất **không đem lợi ích rõ ràng**, nhưng punctuation token lại có ích cho NER. Kết luận thực dụng là: **không cần ép chung segmentation và NER vào một mô hình duy nhất**; nên tách bước, nhưng cho NER dùng thông tin câu đã chuẩn hóa và giữ dấu câu nội bộ khi hợp lý. ¹⁴

Bảng so sánh lựa chọn NER

Lựa chọn	Hỗ trợ đã được tài liệu xác nhận	Offline	Giấy phép	Ưu điểm	Hạn chế với HCH	Khuyến nghị
HanLP	Có NER cho Chinese <code>pku</code> , <code>msra</code> và multilingual <code>ontonotes</code> ; input mô hình ở mức sentence; format span (entity, type, begin, end)	Có	Code Apache 2.0; docs nêu pretrained models/ RESTful APIs dưới CC BY-NC-SA 4.0	Hệ sinh thái mạnh, span format rõ, dễ tích hợp pipeline	Không có tài liệu chính thức nói pretrained NER của HanLP là cho Classical Chinese/ historical Chinese	Dùng làm baseline kỹ thuật hoặc format bridge, không làm model chính ¹⁵
CKIP Transformers	Docs v0.3.4 công bố Traditional Chinese models cho WS/POS/ NER; mô hình NER dùng input là <code>list of sentences</code> ; tập NER dựa trên OntoNotes split	Có	GPL-3.0	Rất hợp phần thể; dễ chạy với Hugging Face	Không phải ancient-specific; cần sentence segmentation trước	Baseline mạnh cho phần thể, nhưng không nên dùng trực tiếp làm HCH NER cuối ¹⁶
Stanza	Có Chinese NER trên OntoNotes với F1 công bố 79.2; hỗ trợ train custom NER bằng BIOES	Có	Apache-2.0	Dễ huấn luyện custom model; training docs rõ	Chinese pretrained model là modern OntoNotes, không phải cổ văn	Hợp cho custom training nếu muốn stack gọn, không hợp zero-shot historical NER ¹⁷
spaCy <code>zh_core_web_trf</code>	Chinese transformer pipeline <code>3.8.0</code> ; components gồm <code>transformer</code> , <code>tagger</code> , <code>parser</code> , <code>ner</code> ; nguồn là OntoNotes 5, <code>bert-base-chinese</code> ; genre là blogs/news/ comments	Có	MIT	Kỹ thuật tốt, huấn luyện/ fine-tune thuận tiện	Dữ liệu huấn luyện là văn bản web hiện đại; không có claim hỗ trợ classical Chinese	Chỉ nên dùng làm modern baseline hoặc annotation helper ¹⁸

Lựa chọn	Hỗ trợ đã được tài liệu xác nhận	Offline	Giấy phép	Ưu điểm	Hạn chế với HCH	Khuyến nghị
Transformers fine-tune trên backbone cổ văn	Hugging Face hỗ trợ token classification; có offline mode qua <code>HF_HUB_OFFLINE=1</code> ; các backbone cổ văn sẵn có gồm GuwenBERT, SikuBERT/ SikuRoBERTa, GujiRoBERTa	Có	Tùy model; GuwenBERT Apache-2.0, SikuBERT Apache-2.0; một số model card cộng đồng còn thiếu thông tin giấy phép/ miêu tả	Đây là con đường phù hợp nhất để thích nghi domain sử học HCH	Cần gold annotation; phải tự quản trị nhãn, chia train/dev/test, và giấy phép model/dataset	Khuyến nghị chính cho HCH NER ¹⁹

Nếu buộc phải trả lời “mô hình nào nên dùng”, tôi đề xuất một câu trả lời có điều kiện. **Không dùng trực tiếp HanLP, CKIP, spaCy hoặc Stanza như model đích cho corpus HCH**; thay vào đó, dùng một trong ba framework đó làm baseline và làm hạ tầng đọc/ghi dữ liệu. **Model đích nên là Transformers fine-tune trên backbone cổ văn**, ưu tiên **SikuBERT/SikuRoBERTa** nếu mục tiêu hàng đầu là giữ **phần thể**, hoặc **GuwenBERT** nếu muốn tận dụng hệ sinh thái/performance tổng quát đã được benchmark trong WYWEB. Nếu có quyền truy cập và kiểm tra license đầy đủ, **GujiRoBERTa** rất đáng thử vì các hệ đứng đầu EvaHan2025 đều dựa trên nó; tuy nhiên model card công khai mà tôi truy xuất được hiện còn nghèo mô tả và không đủ thông tin license/training data để tôi khuyến nghị dùng ngay cho đồ án mà không kiểm chứng thêm. ²⁰

Schema dữ liệu và bộ nhãn đề xuất

Với quy mô đồ án sinh viên nhưng vẫn muốn giữ giá trị học thuật, schema nên theo nguyên tắc: **nhắn ít nhưng giàu thông tin**. Từ các benchmark hiện có, nhóm nhãn lịch sử xuất hiện ổn định nhất là **PERSON, LOCATION/GEO, BOOK, OFFICIAL_TITLE, COUNTRY/POLITY, TIME**; EvaHan2025 dùng các nhãn tương ứng cho hai tập lịch sử, còn GuNER2023 cho thấy một schema 3 nhãn rất mạnh nhưng quá hẹp cho nghiên cứu sử liệu tổng quát. Từ đó, tôi khuyến nghị HCH dùng **9 nhãn lõi** ở pha đầu: **PERSON, LOCATION, POLITY, DYNASTY, OFFICIAL_TITLE, TIME, BOOK, EVENT, ETHNIC_GROUP**. Đây là **đề xuất suy luận** dựa trên benchmark hiện có và đặc thù sử học Trung Quốc, không phải schema chuẩn đã được một benchmark duy nhất xác lập. ²¹

Bộ nhãn NER đề xuất

Nhãn	Mô tả gán nhãn	Ví dụ điển hình	Ghi chú triển khai
PERSON	Tên người lịch sử, thụy hiệu/miếu hiệu khi dùng như tên riêng	高祖, 蘇秦	Bao gồm biệt xưng nếu thực sự quy chiếu một cá nhân

Nhãn	Mô tả gán nhãn	Ví dụ điển hình	Ghi chú triển khai
LOCATION	Địa danh tự nhiên hoặc hành chính dùng như nơi chốn	長安, 沛豐邑, 邵陽縣	Không dùng cho quốc hiệu/chính thể
POLITY	Quốc hiệu, nước chư hầu, chính thể, thực thể chính trị	秦, 漢, 吳	Tách riêng với LOCATION để hữu ích cho sử học
DYNASTY	Tên triều đại khi dùng như mốc triều đại/chế độ lịch đại	唐, 宋, 北魏	Nếu là thành tố của biểu thức thời gian, xem quy tắc ưu tiên bên dưới
OFFICIAL_TITLE	Chức quan, phẩm hàm, chức tước quan phương	中大夫, 尚書令	Rất quan trọng trong nguồn sử
TIME	Niên đại, năm trị vì, mùa/tháng/ngày, biểu thức thời gian	三十四年, 建安五年	Có thể nuốt trọn span dài thay vì gán nhãn lồng
BOOK	Tên sách, thiên, văn bản, điển tịch	易, 漢書, 臨川集	Hữu ích cho liên văn bản và chú dẫn
EVENT	Biến cố, chiến dịch, loạn, hội nghị, cải chế	長平之戰, 安史之亂	Để pha đầu, chỉ gán cho event đã lexicalized rõ
ETHNIC_GROUP	Tộc danh, nhóm người, dân tộc/cộng đồng lịch sử	匈奴, 鮮卑	Tách riêng vì rất thường gặp trong sử Bắc triều, biên thùy

Để tránh nested annotation quá nặng tay ở giai đoạn đồ án, tôi khuyên dùng **một lớp span phẳng** ở pha một, với các quy tắc ưu tiên sau. Nếu một triều đại nằm trong biểu thức thời gian như **唐初**, ưu tiên gán **toàn span là TIME** thay vì vừa **DYNASTY** vừa **TIME**. Nếu một quốc hiệu vừa chỉ chính thể vừa chỉ vùng địa lý trong ngữ cảnh cụ thể, ưu tiên theo **vai nghĩa chính của câu**: nói về lãnh thổ/đường đi thì **LOCATION**; nói về nhà nước/chế độ thì **POLITY**. Đây là lựa chọn giảm chi phí gán nhãn và giúp train/eval ổn định hơn; nếu sau này muốn học thuật sâu hơn, bạn có thể bổ sung trường **facets** hoặc **normalized_type** thay vì đưa nested NER ngay từ đầu. Khuyến nghị này được hỗ trợ gián tiếp bởi việc EvaHan2025 dùng whole-entity evaluation và các corpus hiện có chưa thống nhất hierarchy đầy đủ. ¹¹

Schema JSONL mở rộng đề xuất

Tôi khuyến nghị **không lưu sentences chỉ là mảng string**, vì sẽ khó giữ offset và provenance. Tốt hơn là lưu sentence như span trên **text**, và entities là span toàn đoạn, có liên kết câu. Quy ước offset nên là **start inclusive, end exclusive** để đồng bộ với HanLP và thuận tiện cho Python slicing. ²²

```
{
  "id": "hanshu-000001",
  "work_id": "漢書",
  "title": "漢書",
```

```

"volume": "卷一",
"section": "高帝紀",
"text": "高祖，沛豐邑中陽里人也。",
"text_script": "traditional",
"source_file": "漢書_full.txt",
"source_line_start": 123,
"source_line_end": 123,
"sentences": [
  {
    "sid": "hanshu-000001-s1",
    "start": 0,
    "end": 12,
    "text": "高祖，沛豐邑中陽里人也。",
    "method": "rule",
    "review_status": "checked"
  }
],
"entities": [
  {
    "eid": "hanshu-000001-e1",
    "start": 0,
    "end": 2,
    "text": "高祖",
    "label": "PERSON",
    "sentence_id": "hanshu-000001-s1",
    "normalized": "劉邦",
    "certainty": "high",
    "note": null
  },
  {
    "eid": "hanshu-000001-e2",
    "start": 3,
    "end": 9,
    "text": "沛豐邑中陽里",
    "label": "LOCATION",
    "sentence_id": "hanshu-000001-s1",
    "normalized": null,
    "certainty": "high",
    "note": null
  }
],
"annotation": {
  "sentence_guideline_version": "0.1",
  "ner_guideline_version": "0.1"
}
}

```


Thiết kế này giải quyết ba việc cùng lúc. Một là giữ được **raw text nguyên vẹn**. Hai là hỗ trợ truy vết ngược về dòng nguồn và phiên bản guideline. Ba là cho phép sau này sinh các định dạng train khác nhau như BIOES/BMES TSV, spaCy spans, Stanza BIOES hay HanLP tuples từ cùng một nguồn vàng thống nhất. Đây là phần thiết kế đề xuất của báo cáo, dựa trên fact rằng HanLP dùng tuple span, Stanza huấn luyện NER ở BIOES, còn benchmark EvaHan2025 ở BMES/whole-entity. ²³

Pipeline triển khai, gán nhãn và đánh giá

Pipeline đề xuất từ `build/corpus.jsonl` đến corpus có câu và entity gồm sáu bước. Trước hết, thêm một bước **pre-normalization không phá raw**: chuẩn hóa newline, nhận diện span chú thích/ngoặc, khoanh vùng các pattern học thuật như `<案...>`, `(...)`, các nhan đề trong `<...>`, nhưng chỉ gán metadata chứ không xóa khỏi `text`. Tiếp theo, chạy **sentence segmentation tầng một** bằng rules trên punctuation mạnh và paired punctuation. Sau đó, tạo một hàng đợi “uncertain segments” cho các trường hợp như độ dài bất thường, không có `。 ! ?`, có nhiều dấu `； :`, hoặc xen chú thích học thuật. Chỉ trên tập uncertain này mới chạy model cổ văn. Sau khi có câu, mới chạy **pre-annotation NER** bằng model fine-tune hoặc baseline, rồi đưa vào giao diện gán nhãn thủ công để sửa. Sau cùng, xuất song song một bản **gold JSONL** và các bản **train-ready** cho framework huấn luyện. Toàn bộ cách chia tầng này nhất quán với tài liệu của CKIP và HanLP, vốn đều giả định đầu vào NER/sequence processing ở mức câu, và với kết quả Ge 2022 cho thấy punctuation hữu ích cho NER. ²⁴

Về kích thước gold-standard, tôi không thấy một nguồn nào cho ra “con số đúng duy nhất” cho đồ án, nên đây là **khuyến nghị suy luận** dựa trên quy mô benchmark liên quan. GuNER2023 dùng hơn **150k chữ** với 3 nhãn và EvaHan2025 dùng các tập lịch sử cỡ **178k** và **115k ký tự**. Với đồ án sinh viên, một mục tiêu thực tế hơn là: **pilot guideline** khoảng **8k-12k ký tự** double-annotated để sửa nhãn; **gold sentence segmentation** khoảng **20k-30k ký tự** trải đều trên 8 tác phẩm; **gold NER** khoảng **50k-80k ký tự** hoặc tương đương khoảng **800-1.500 câu** đã tách chuẩn. Nếu tài nguyên gán nhãn hạn chế, hãy ưu tiên **đa dạng tác phẩm và thể loại đoạn văn** trước khi cố chạy theo quy mô lớn. ²⁵

Cách chia train/dev/test không nên random theo dòng thuần túy, vì như vậy rất dễ rò rỉ phong cách thư tịch hoặc cụm thực thể giữa ba tập. Tôi khuyến nghị chia **theo passage**, có **stratify theo tác phẩm**, và giữ nguyên các đoạn liên tiếp từ cùng ngữ cảnh trong cùng split. Một cấu hình dễ dùng là **70/15/15** nếu huấn luyện model, hoặc **80/20** nếu giai đoạn đầu chỉ làm dev-test benchmark. Riêng phần pilot guideline nên có **15-20%** mẫu được **double annotation**, sau đó adjudication để chốt guideline trước khi scale up. Đây là thực hành đề xuất của báo cáo; nó được hỗ trợ gián tiếp bởi việc các benchmark cổ văn gần đây đều dùng split chuẩn và whole-entity metrics chứ không đánh giá theo ký tự rời rạc. ²⁶

Về metric, với **tách câu**, dùng **sentence boundary precision, recall, F1** trên tập gán tay; mỗi ranh giới câu là một decision point. Có thể báo thêm **exact sentence match rate** để đo trải nghiệm downstream. Với **NER**, metric chính nên là **entity-level precision, recall, F1** theo **strict match**: đúng đồng thời span và label. Báo thêm **relaxed match** như một metric phụ, trong đó span overlap hợp lệ khi chênh biên rất nhỏ hoặc label nằm trong cặp dễ lẫn đã định nghĩa trước, nhưng không được dùng thay cho metric chính. Việc nhấn mạnh **whole-entity evaluation** được benchmark EvaHan2025 nêu rất rõ; còn Stanza, Hugging Face và phần lớn pipeline token classification vẫn thuận tiện cho huấn luyện ở BIOES/BMES, miễn là gold chuẩn được lưu ở dạng span. ²⁷

Rủi ro, giấy phép và nguồn chính

Rủi ro kỹ thuật lớn nhất là **đem model tiếng Trung hiện đại áp thẳng vào văn ngôn**. WYWEB nói khá thẳng rằng các mô hình pretrain trên modern Chinese **không thích nghi tốt** với classical Chinese. spaCy Chinese pipeline công bố nguồn là **OntoNotes 5 + bert-base-chinese** trên **blogs/news/comments**; Stanza Chinese NER cũng công bố Chinese model trên **OntoNotes**; CKIP thì mạnh ở **Traditional Chinese** nhưng tài liệu chính thức vẫn là mô hình NER/POS/WS cho dữ liệu hiện đại đã chia sẵn, đầu vào là list câu. Vì vậy, nếu dùng các công cụ này trực tiếp cho HCH, lỗi thường gặp sẽ là **trượt biên thực thể, gán sai chức quan/triều đại thành person/location** সাধারণ, **không xử lý tốt văn phong văn tấu của sử thư**, và **nhầm tên sách/tướng hiệu với common noun**. Đây là suy luận hợp lý từ domain mismatch mà các nguồn đã nêu.

28

Về giấy phép, đây là phần cần kiểm rất kỹ trước khi chốt stack. **spaCy Chinese pipelines** công bố MIT. **Stanza** là **Apache License 2.0**. **CKIP Transformers** là **GPL-3.0**, nên nếu bạn đóng gói/phân phối phần mềm hoặc artifact kèm code, cần cân nhắc tương thích giấy phép. **XunziALLM** repo GitHub là **Apache-2.0**. **KoichiYasuoka sentence segmentation model** trên Hugging Face là **Apache-2.0**. **GuwenBERT** và **SikuBERT** cũng công bố **Apache-2.0**. Riêng **HanLP** có điểm rất dễ bị bỏ sót: trang demo nêu **Apache License 2.0** cho thư viện/code, nhưng tutorial của HanLP ghi rằng **models và RESTful APIs nằm dưới CC BY-NC-SA 4.0**; điều này có thể tạo ràng buộc phi thương mại cho pretrained resources.

29

Một rủi ro khác là **độ minh bạch không đồng đều của model card/dataset card cổ văn**. Ví dụ, model page **GujiRoBERTa_jian_fan** mà tôi truy xuất được có phần model card rất sơ sài, chứa nhiều chỗ “More information needed”, không nêu rõ training/eval data hữu ích cho việc tái lập học thuật. Điều đó không có nghĩa model kém; nó chỉ có nghĩa là **không nên đưa thẳng vào báo cáo đồ án như một nguồn “đã kiểm chứng đầy đủ”** nếu chưa có thêm tài liệu gốc hoặc xác nhận license. Vì vậy, nếu bạn chọn GujiRoBERTa làm backbone, hãy trích dẫn paper shared-task đi kèm và lưu riêng biên bản kiểm tra license/model provenance.

30

Các nguồn trọng yếu nhất để bám khi triển khai tiếp là bộ đôi **EvaHan2024** cho segmentation/punctuation và **EvaHan2025 + GuNER2023** cho NER lịch sử; nhóm nguồn công cụ chính thức nên gồm **HanLP docs**, **CKIP Transformers docs**, **Stanza docs/repo**, **spaCy model release**, cùng model cards của **GuwenBERT**, **SikuBERT**, và **KoichiYasuoka sentence-segmentation model**. Nếu phải ưu tiên ít nguồn để thiết kế guideline nhanh, tôi sẽ chọn: **EvaHan2025**, **GuNER2023**, **Tang 2021**, **Ge 2022**, **HanLP data format**, **CKIP docs**, và **SikuBERT/GuwenBERT**.

31

1 15 Named Entity Recognition — HanLP Documentation - Hankcs
https://hanlp.hankcs.com/docs/annotations/ner/index.html?utm_source=chatgpt.com

2 11 21 26 27 Overview of EvaHan2025: The First International Evaluation on Ancient Chinese Named Entity Recognition
<https://aclanthology.org/2025.alp-1.19.pdf>

3 31 Overview of EvaHan2024: The First International Evaluation on Ancient Chinese Sentence Segmentation and Punctuation
<https://aclanthology.org/2024.lt4hala-1.27.pdf>

4 5 eos — HanLP Documentation - Hankcs

https://hanlp.hankcs.com/docs/api/hanlp/components/eos.html?utm_source=chatgpt.com

6 10 KoichiYasuoka/roberta-classical-chinese-base-sentence-segmentation · Hugging Face

<https://huggingface.co/KoichiYasuoka/roberta-classical-chinese-base-sentence-segmentation>

7 ethanyt/guwenbert-base · Hugging Face

<https://huggingface.co/ethanyt/guwenbert-base>

8 荀子系列大语言模型

https://github.com/Xunzi-LLM-of-Chinese-classics/XunziALLM?utm_source=chatgpt.com

9 SPEADO: Segmentation and Punctuation for Ancient Chinese Texts via Example Augmentation and Decoding Optimization

<https://aclanthology.org/2024.lt4hala-1.32.pdf>

12 25 CCL23-Eval任务1总结报告:古籍命名实体识别(GuNER2023)(Overview of CCL23-Eval Task 1: Named Entity Recognition in Ancient Chinese Books) - ACL Anthology

<https://aclanthology.org/2023.ccl-3.4/>

13 28 aclanthology.org

<https://aclanthology.org/2023.findings-acl.204.pdf>

14 Construction of NER Model in Ancient Chinese: Solution of EvaHan 2025 Challenge

<https://aclanthology.org/2025.alp-1.20.pdf>

16 24 CKIP Transformers — CKIP Transformers v0.3.4 documentation

<https://ckip-transformers.readthedocs.io/en/stable/main/readme.html>

17 NER Models - Stanza

https://stanfordnlp.github.io/stanza/ner_models.html

18 29 Releases · explosion/spacy-models · GitHub

<https://github.com/explosion/spacy-models/releases/>

19 Token classification - Transformers

https://huggingface.co/docs/transformers/main/tasks/token_classification?utm_source=chatgpt.com

20 arxiv.org

<https://arxiv.org/pdf/2305.14150>

22 23 Data Format — HanLP Documentation

https://hanlp.hankcs.com/docs/data_format.html?utm_source=chatgpt.com

30 hsc748NLP/GujiRoBERTa_jian_fan · Hugging Face

https://huggingface.co/hsc748NLP/GujiRoBERTa_jian_fan